AlphaOrchestra

群智阿尔法：市场状态驱动的多智能体自适应编排与量化决策平台

商业计划项目书

Who to ask → Why they disagree → Who to trust → How much to think

参赛赛事	北京大学金融 AI 智能体创新大赛
参赛赛道	赛道二：量化投资策略与金融科技工具研发
项目阶段	技术方案与核心创新设计已完成；端到端工程闭环已验证；规模化对比实验与消融待完成
团队名称	孙浩霖、潘昊辰、谢永仪
版本日期	2026 年 9 月

一句话定位不是“让更多 Agent 一起投票”，而是让系统在每个市场状态下先选择最值得咨询的一组互补专家，识别分歧来源，再动态决定该信谁、信多少以及是否值得继续增加推理成本。

目录

1. 执行摘要
2. 项目背景与行业机会
3. 用户痛点与需求定义
4. 产品定位与核心价值
5. 技术架构与 Agent 工作流
6. 三项核心创新
7. 工程实现与系统落地方案
8. 数据、实验与评价体系
9. MVP、演示与产品形态
10. 目标市场与客户画像
11. 竞争格局与差异化壁垒
12. 商业模式与定价
13. 市场进入与机构落地路径
14. 合规、风险治理与知识产权
15. 里程碑与研发路线
16. 三年财务情景测算
17. 项目价值与愿景

1. 执行摘要

1.1 项目简介

AlphaOrchestra 是一套面向量化投研机构的市场状态驱动多智能体决策编排平台：系统不再每天无差别调用全部 LLM 投资者 Agent，而是根据市场状态、专家历史能力、信息互补性与调用成本，先动态选择 “今天应该问谁”，再诊断专家之间 “为什么不同意”，最后决定 “应该信谁多少、是否追加定向讨论、何时应当弃权”。

比如，某日为政策冲击日，Router 没有唤醒全部候选 Agent，而是依据市场状态只调用 12 个信息互补的专家，Token 与调用费用随之大幅下降；当基本面 Agent 与新闻 Agent 对同一标的给出相反判断时，系统先诊断冲突来源，再发起一次有边界的定向讨论，最终输出可审计的信号与决策理由。

1.2 项目从哪里来

在相关研究中，MASS（Multi-Agent Simulation Scaling for Portfolio Construction）是具有代表性的多智能体组合构建方法之一。MASS 将异构 LLM 投资者 Agent 直接用于组合构建：每日前向阶段由不同投资风格与不同数据模态的 Agent 生成投资决策，再用共识与分歧形成股票信号；日后通过 Backward Optimization 动态调整 Agent Type 权重。论文报告其在 2023 年 A 股多个股票池以及 2025 年一季度未见数据上的有效性，并开放代码与 SSE50 示例数据，可作为本项目实验中的公开对比基线。

MASS 验证了 “Agent 越多越强” 的 Scaling 方向，而 AlphaOrchestra 回答的是 Scaling 之后的经济性与治理问题——用有限预算选出最有效的独立信息通道，让智能体之间的分歧可诊断、可治理、可审计。

AlphaOrchestra 的创新不在于替换某一个现有优化器，而是独立设计并形成三层可验证的智能体机制：① 事前 Routing 与事后 Aggregation 的双阶段编排；② 结构化分歧诊断与条件式 Debate/Abstention；③ 兼顾信息多样性、冗余、Token/API 成本和市场复杂度的自适应计算预算。最终逻辑是 “Who to ask → Why they disagree → Who to trust → How much to think”。

1.3 为什么有商业价值

MASS 论文已经显示大规模多 Agent 的现实成本：在 512-Agent 配置下，论文报告 SSE50、CSI300、创业板 100 的平均单日 API 费用分别约为 0.679、2.265、1.192 美元，对应平均耗时 125、378、227 秒；尽管作者通过缓存与低频更新降低成本，但随着模型更强、数据模态更多、机构要求更高，冗余 Agent 调用、冲突解释与实时延迟会成为工程瓶颈。

AlphaOrchestra 的商业价值不承诺 “保证收益”，而是面向机构量化投研的三个可量化目标：在相近的 RankIC/Sharpe 水平下减少冗余 Agent 调用和推理成本；在 Regime 切换时更快调整专家组合；把 “为什么选这些专家、为什么对某个冲突触发 Debate、为什么降低仓位” 转化为可审计的 Evidence Trace。

1.4 当前阶段与本次比赛交付

维度	当前状态	本次比赛目标
对比基线	MASS 等公开论文、SSE50 示例数据及可复现实验资源可用	完成统一 Benchmark 复现与实验脚本
创新方案	三项创新已完成模块级设计；其中市场状态编码、智能体路由、基础分歧诊断与风险暴露控制初版已实现，并完成阶段性验证实验（见 8.2 节）	补齐定向 Debate/Abstention、Agent 相似度矩阵与动态计算预算，形成完整闭环并通过规模化消融验证
实验	已完成端到端阶段性验证实验：全流程跑通并产出 IC/RankIC 评估结果（见 8.2 节），未将规划目标冒充已实现结果	完成核心消融、性能–成本前沿和 Regime 解释性实验
产品	处于概念验证阶段	提供可演示 Dashboard/Trace 与 Shadow Mode 原型
商业	尚无已签客户，不虚构订单	形成机构访谈清单、POC 报价与私有化交付方案

2. 项目背景与行业机会

2.1 “为什么现在”：量化与金融 Agent 同时进入工程化阶段

一方面，中国私募证券基金已经形成大规模机构化市场：中国证券投资基金业协会披露，2025 年私募证券投资基金规模首次突破 7 万亿元。对本项目而言，这一数字并不等同于 “量化 Agent 软件市场规模”，但它说明潜在 B2B 客户基础庞大，机构在投研效率、系统化决策和风险治理上的需求具有现实基础。

另一方面，金融 AI 正在从单次问答和单 Agent 助手走向可执行、可组合、可治理的 Agent 系统。MASS、TradingAgents、FinCON 等研究说明多角色协作已进入量化投资决策；更一般的多智能体研究也开始从静态拓扑转向动态 Orchestration，例如 Evolving Orchestration 以中央编排器动态排序和优先调用 Agent，并以降低计算成本为明确目标。

政策环境同样强化 “可控、可审计、风险优先” 的落地逻辑。中国证监会《证券市场程序化交易管理规定（试行）》自 2024 年 10 月 8 日起实施，强调报告、实时监测、风险防控和信息系统管理；证监会《加强证券期货业标准化工作三年行动计划（2024–2026 年）》明确将大模型和人工智能纳入金融科技标准研制重点。

Why Now 模型能力足以承担金融信息理解与多角色推理；开源量化/Agent 框架降低工程门槛；同时监管与机构治理要求推动系统从 “能给答案” 升级为 “能解释、能审计、能限权、能控制成本”。

2.2 代表性方法已经解决了什么、还缺什么

以 MASS 等代表性方法为例，其将组合构建建模为 “每日前向决策 → 按 Agent 类型权重形成加权共识与分歧信号 → 依据近期真实收益反向优化权重” 的在线循环；公开论文与实现为本项目提供了可复现的模块参照与公平对比基线。

公开论文与实现为对比实验提供了可复现参照：典型系统通常包含异构 Agent 执行、信号聚合、历史反馈与动态权重优化等模块。本项目在此问题基础上采用独立的模块化工程实现，核心的 Market State、Router、Structured Disagreement、Diagnosis、Adaptive Aggregation、Cost/Memory 与风险接口均按 AlphaOrchestra 架构自主设计，并通过统一实验脚本与公开基线进行公平比较。上述方法在机构落地时的缺口，将在下一章归纳为四类高频用户痛点及其应对。

3. 用户痛点与需求定义

3.1 目标用户

首批目标用户不是散户，而是具备数据与回测基础设施、愿意采用大模型但对成本和治理敏感的 B2B 机构：量化私募研究团队、券商自营/资管量化团队、公募量化与指数增强团队、金融科技投研平台，以及大型资管机构的 AI/模型风险团队。

3.2 四个高频痛点

痛点	传统处理方式	**AlphaOrchestra** 要解决什么
Agent 调用 “越多越好” 难持续	固定配置、全量并行、人工调并发	按市场状态和边际信息价值动态组队
模型意见冲突难解释	均值/投票/标准差惩罚	识别方向、证据、期限、置信度与语义冲突
动态权重存在滞后	只看近几日收益/IC 调整	把当前 Regime 与当日具体输出纳入动态信任
AI 投研难审计	只保留最终结论	保存 selection score、证据、debate 原因、abstain 原因和成本

3.3 客户购买的不是 “一个神奇 Alpha”

产品定位必须避免 “卖一个黑箱策略” 的短视逻辑。机构真正可能付费的是一个可接入自有数据、模型、策略和风控模块的 Agentic Control Plane：它把已有研究基础设施变成可调度的 Tools，把 LLM 专家变成受预算和规则约束的研究资源，再以结构化 Trace 帮助研究员复盘和治理。

4. 产品定位与核心价值

4.1 产品定义

产品名称 AlphaOrchestra（群智阿尔法）——面向机构量化投研的 “多智能体编排与可信聚合中枢”。

其产品边界是 “决策辅助与投研编排”，不是直接获得无限交易权限。第一阶段以 Research/Shadow Mode 运行：系统输出候选股票排序、专家选择理由、冲突诊断、置信度和组合建议，最终是否进入实盘由机构现有 Portfolio Optimizer、风险系统和人工审批决定。

4.2 三层产品架构

层级	核心组件	客户可见价值
Agentic Control Plane	Market State Encoder、Router、Diagnosis、Aggregation、Memory	动态决定问谁、何时讨论、何时停止
Quant / Model Tool Layer	数据接口、LLM 专家、回测器、风险模型、成本模型、优化器	保留机构现有基础设施，不要求全部重建
Evidence & Governance Layer	决策 Trace、成本账单、版本记录、阈值与权限	每次决策可解释、可复现、可审计

4.3 核心价值主张

价值	目标指标（待实验/**POC** 验证）
更有效的信息利用	在同等 Agent 调用数下，提高 RankIC/ICIR、Sharpe 或 Regime 稳定性
更低推理成本	在接近基线表现的条件下，目标减少 30%–60% 的 Agent/Token 调用
更快适应市场变化	缩短 Regime 变化后的专家组合恢复时间，减少 “昨日冠军” 权重惯性
更可信的冲突处理	Debate 只在高价值冲突触发；低置信度场景允许 Abstain/降暴露

价值	目标指标（待实验/**POC** 验证）
机构级可治理	完整记录输入版本、Tool Call、Agent 选择、证据、成本与最终审批

5. 技术架构与 **Agent** 工作流

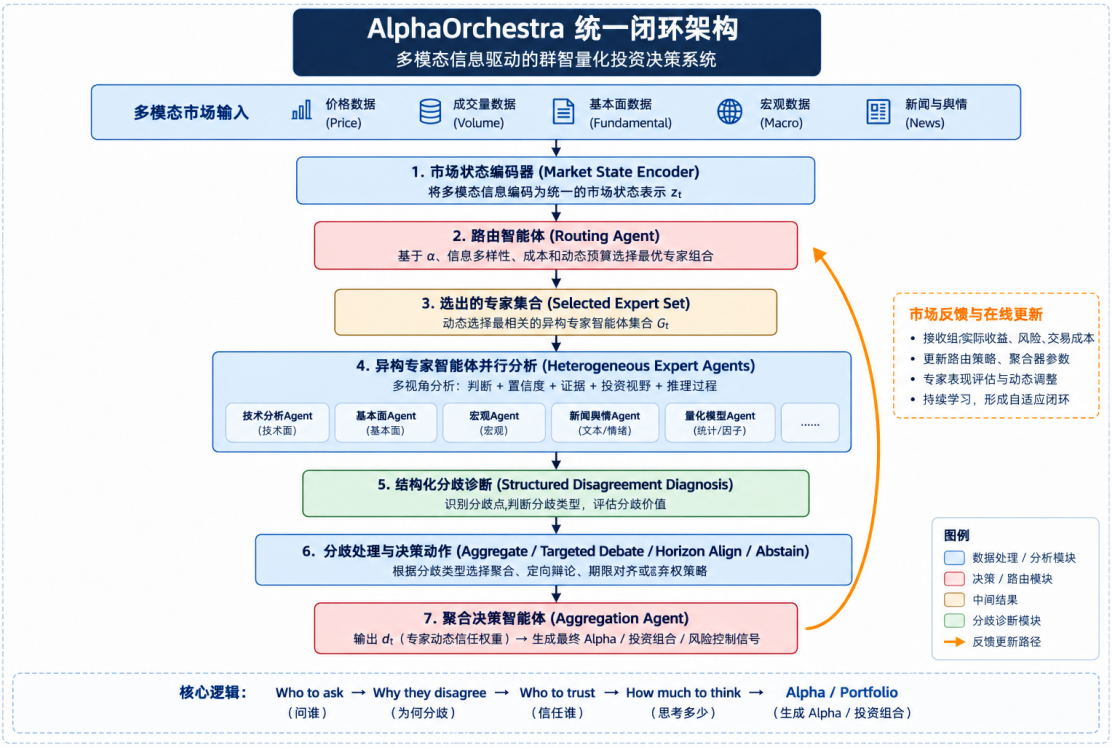


图 1 AlphaOrchestra 统一闭环：Selection → Expert Reasoning → Conflict Resolution → Aggregation → Portfolio Feedback

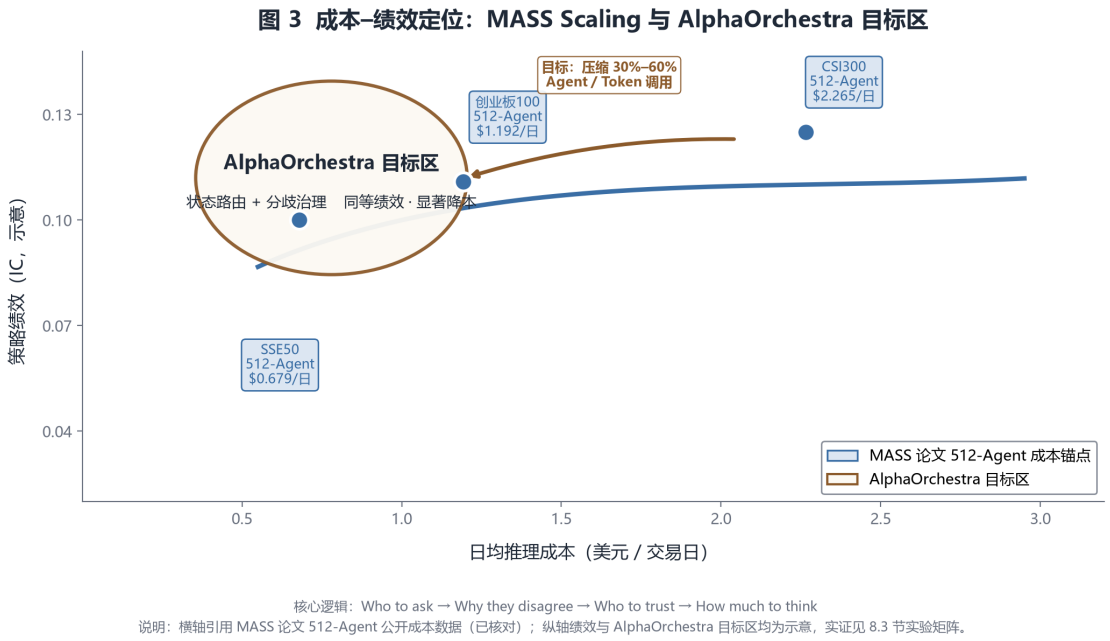


图 3 成本–绩效定位：MASS Scaling（论文成本锚点）与 AlphaOrchestra 目标区（目标区为示意，实证见 8.3 节实验矩阵）

5.1 Agent 到底在哪里

本项目中的 “Agent” 并不等于一个 LLM API 调用。LLM 可以承担 Router/Diagnosis 等控制器中的推理与解释能力，但完整 Agent 还包括状态、动作空间、工具、Memory、预算与停止规则。真正的智能体性体现在：同一个系统面对不同市场状态和不同冲突证据，会选择不同的专家集合、不同的 Debate 路径和不同的停止/弃权动作。

5.2 每日运行流程

1. 生成 Market State Card：把价格、波动率、成交量、流动性、市场宽度、风格收益、宏观与文本事件编码为固定维向量 $z_t=[z_t^{num},z_t^{event}]$；$z_t^{num}$ 包括 1/5/20 日市场收益、20 日实现波动率、成交额/换手、流动性、市场宽度、主要风格因子收益及利率、CPI、估值分位等宏观变量，并用滚动 z-score 或 percentile 标准化；z_t^{event} 表示新闻、政策、财报等文本事件的类别特征或固定维 embedding/projection。

2. Routing Agent 读取 z_t、各 Expert Type 历史表现 H_t、Profile P 和预算 B_t，输出 Type-level 调用变量 $g_{i,t}\in\{0,1\}$；其中 i 表示 Expert/Investor Type，k 表示该 Type 下的 Individual Agent/replica。

3. 仅被选中的 Expert Type 下的 Individual Agents 执行 LLM/模型推理，并统一输出 Prediction、Confidence、Horizon、Evidence、Reasoning；Type 内多个 replica 可用于不同候选股票视图、随机采样或 ensemble，并先聚合为该 Type 意见。

4. 确定性程序计算结构化分歧特征；Diagnosis Agent 解释主要冲突来源，并从 Aggregate / Targeted Debate / Horizon Align / Abstain 中选择动作。

5. Aggregation Agent 综合市场状态、Type-level 结构化输出、历史表现和历史权重先验 d_hist，输出 Type-level 动态信任权重 $d_{i,t}$，即问完以后信第 i 类专家多少。
6. 形成 Final Alpha Signal 并交给 Portfolio 层；实盘/回测收益、风险、换手与推理成本回写 Memory，更新 Router、Aggregator 与 Expert Type/Individual Agent Reputation。

6. 三项核心创新

6.1 创新一：Dual-Stage Agent Orchestration

核心思想先决定 **"问哪一类专家"**（$\mathbf{g_{i,t}}$），再决定 **"信这一类专家多少"**（$\mathbf{d_{i,t}}$）。这里 **i** 表示 **Expert/Investor Type**，**k** 表示该 **Type** 下的 **Individual Agent/replica**；**Type** 内输出先聚合为该 **Type** 意见。原 **MASS** 可理解为 $\mathbf{g_{i,t}=1}$，即所有类型均参与，只动态学习 $\mathbf{d_{i,t}}$；**AlphaOrchestra** 在此基础上新增事前选择 $\mathbf{g_{i,t}}$。

Router 输入由四部分组成：固定维市场状态 z_t；各 Expert Type 近 5/20 日 RankIC、hit rate、回撤、不同 Regime 表现等历史能力 H_t；数据模态、投资风格、预测期限、能力边界等 Profile；以及当日 Type 数、Token/API 费用、延迟等预算 B_t。第一版可用 Contextual Gating Network（MLP + Top-K/阈值）产生调用价值 $q_{i,t}$，再得到 $g_{i,t}\in\{0,1\}$。

事后 Aggregation 不再只依赖近期收益，而是可表示为 $s_{i,t}=f\theta(z_t,o_{i,t},H_{i,t},d_{i,t}\text{^hist})$，再对被选 Expert Type 做 Softmax 得到 $d_{i,t}$。这使系统能同时利用历史先验、当前市场状态和 "该类专家今天具体说了什么"。

当前实现状态：Market State Encoder、Routing Agent 与信号聚合（Aggregation）的初版已实现，并已进入端到端验证实验闭环（见 8.2 节）。

6.2 创新二：Structured Disagreement Diagnosis

核心思想从 "分歧有多大" 升级为 "为什么分歧，以及这种分歧应该被讨论、对齐、忽略还是用于降低风险"。

代表性的共识—分歧聚合方法通常将分歧压缩为单一加权标准差 σ。本项目要求 Expert Agent 结构化输出，并以确定性程序计算分歧向量 D=[D_pred,D_evidence,D_horizon,D_conf,D_semantic]：分别表示预测方向、证据集合、预测期限、置信度与语义推理差异。之后 Diagnosis Agent 只能基于这些结构化证据给出冲突类别，例如 model noise、information conflict、horizon conflict、regime conflict、high uncertainty。

若 Fundamental Agent 基于盈利改善看多而 News/Policy Agent 基于监管事件看空，系统不会让所有 Agent 无限讨论，而是先统一投资期限，再向冲突双方提出同一个有边界的问题；若高分歧同时伴随普遍低置信度且 Debate 无法收敛，则输出系统

置信度 c_sys 并触发 Abstain 或降低仓位。这相当于给多智能体组合增加 “我不知道” 的能力。

冲突处理后的第 i 类专家对股票 s 在 t 时刻的预测记为 $\tilde{p}_{i,s,t}$：Aggregate 保持原预测，Targeted Debate 使用讨论后的修正预测，Horizon Align 使用统一期限后的重新预测，Abstain 通过系统置信度降低风险暴露而非强制生成方向。Aggregation Agent 输出 $d_{i,t}=g_{i,t}\exp(s_{i,t})/\Sigma_j g_{j,t}\exp(s_{j,t})$，其中 $s_{i,t}$ 为第 i 类专家 trust score，因此 $g_{i,t}=0$ 时 $d_{i,t}=0$ 且 $\Sigma_i d_{i,t}=1$。聚合预测 $\mu_{s,t}=\Sigma_i d_{i,t}\tilde{p}_{i,s,t}$，系统置信度 $c_sys_{s,t}\in[0,1]$，最终 $Alpha_{s,t}=c_sys_{s,t}\mu_{s,t}$；当 $c_sys_{s,t}<\tau_abstain$ 时，可令该股票 Alpha 归零或显著降低对应风险暴露。

当前实现状态：分歧严重度计算与风险暴露控制（Exposure Control）已实现并进入实验闭环；基于 LLM 的分歧归因解释与定向 Debate 机制已完成设计，为下一迭代重点。

6.3 创新三：**Diversity & Cost-Aware Adaptive Computation**

核心思想 **Raw Agent Count ≠ Effective Independent Information Count**。目标不是调用最多 **Agent**，而是用最少的一组互补专家获得更高的有效信息密度。**Innovation 1** 解决决策结构问题：在专家推理前新增独立 **Selection** 变量 $\mathbf{g}_t$，并将其与事后 **Aggregation** 权重 $\mathbf{d}_t$ 分离；**Innovation 3** 解决 **Selection** 的优化目标问题：在既有 **Routing** 机制上进一步权衡信息价值、信息互补性和计算成本，并动态决定计算预算。

系统为每个 Expert Type 维护长期 Representation，包括 Data Modality、Investment Style、历史预测序列、Reasoning Embedding、Token/Latency/API Cost，并构造相似度 $R_{ij,t}$。Router 目标可写为：最大化 $\Sigma_i g_i U_{i,t} - \lambda\Sigma_{i<j} g_i g_j R_{ij,t} - \eta\Sigma_i g_i c_{i,t}$，即奖励预期信息/Alpha 价值，惩罚专家冗余与推理成本。可计算定义为：$U_{i,t}=w_1 RankIC_{i,t}\text{^}recent+w_2 HitRate_{i,t}+w_3 RegimeScore_{i,t}$，可用近 5/20 日滚动能力指标；$R_{ij,t}=\gamma_1 Corr(Pred_i,Pred_j)+\gamma_2 CosSim(Reason_i,Reason_j)+\gamma_3 DataOverlap(i,j)$；$c_{i,t}=a TokenCost_{i,t}+b Latency_{i,t}+c APICost_{i,t}$。各项进入目标函数前统一尺度归一化。第一版用贪心选择即可，不必直接上复杂组合优化。

同时定义 Market Complexity=f(Volatility, Event Intensity, OOD, Uncertainty)，先形成事前 Routing 预算 $B_t\text{^}route=f(MarketComplexity_t)$，在 Expert Agent 执行前确定最大调用 Expert Type 数量与初始 Token/API Budget；收到专家输出并完成分歧诊断后，再形成事后 Deliberation 预算 $B_{s,t}\text{^}debate=f(MarketComplexity_t,D_{s,t},Uncertainty_{s,t})$，决定是否触发 Debate、Debate 轮数与额外 Token Budget。正常市场少问、少讨论；重大政策或极端波动时允许更多互补 Agent 和更高 Debate 预算。这样 “How much to think” 是在推理过程中动态调整，也可以画出 Performance–Cost Frontier。（见图 3）

创新	最重要的消融问题	商业映射
双阶段编排	公开基线（MASS）vs Router-only vs Aggregator-only vs Router+Aggregator	减少无效调用、提升状态适应

创新	最重要的消融问题	商业映射
结构化分歧	Consensus vs Consensus−σ vs Diagnosis vs Diagnosis+Debate+Abstention	降低 “错误共识” 和无意义争论
多样性与成本	Top-K vs Diversity-aware vs Diversity+Cost-aware	直接形成 Token/延迟/收益的 ROI 证据

当前实现状态：路由模块已实现信息价值、信息差异与调用成本之间权衡的基础逻辑；完整的 Agent 相似度矩阵与动态计算预算为下一阶段规划工作。

7. 工程实现与系统落地方案

7.1 为什么具备快速落地条件

AlphaOrchestra 采用独立、模块化的工程架构实现核心能力。公开论文、开源数据与公开实现主要用于相关工作研究、Benchmark 复现和实验对照，以确保结果可比；项目核心的 Market State Encoder、Routing、Structured Disagreement、Diagnosis、Conditional Debate、Adaptive Aggregation、Cost-aware Budget、Memory 与 Evidence Trace 由团队按照本项目架构自主设计与实现。

截至本版本，Market State Encoder、Routing、基础分歧诊断与风险暴露控制的初版已由团队自主实现，并通过阶段性验证实验完成端到端流程检验（见 8.2 节）；定向 Debate、Agent 相似度矩阵与动态计算预算将在后续迭代中落地。

7.2 核心模块实现位置

AlphaOrchestra 核心模块	主要职责	自主实现重点
orchestration/executor.py	交易日级任务编排与 Agent 执行	在执行前接入 Market State + Router，仅提交 selected agents；记录调用成本与路由轨迹
routing/router.py	基于 z_t、H_t、Profile、Budget 输出 g_t	实现 Type-level selection，并记录路由分数与未选择原因
agents/expert_agent.py + prompts	异构 LLM 专家生成策略与股票判断	统一 JSON Schema：prediction/confidence/horizon/evidence/reasoning
aggregation/signal_engine.py	计算基础共识/分歧并形成候选信号	加入 structured disagreement、diagnosis 动作与 adaptive aggregation
diagnosis/disagreement.py	计算 D_pred、D_evidence、D_horizon、D_conf、D_semantic 并提供 Diagnosis 接口	保持确定性分歧特征与 LLM 归因解释解耦

AlphaOrchestra 核心模块	主要职责	自主实现重点
optimization/reputation.py	维护历史 Agent 能力、信誉与动态权重先验	使用 d_hist 作为历史先验，并与 Aggregator/Router 学习权重及成本目标联动
memory/agent_registry.py	维护 Agent 长期状态与决策记忆	保存 Agent Profile、相似度、历史 Regime 表现、Debate 记录、Token/latency、reputation
risk/optimizer_adapter.py	连接风险模型与组合优化器	商业版以接口方式接入机构现有风险模型/组合优化器，Agent 不绕过硬约束
cost/budget_manager.py	跟踪 Token/API/Latency 并管理 ex-ante / ex-post budget	支持 Routing 预算与 Deliberation 预算分阶段控制

7.3 LLM 与确定性计算的边界

任务	执行主体	原因
IC/RankIC、收益、风险、相似度、Token 计费	Python/统计程序	必须确定、可复现
Market numeric state	数值模型/规则	避免 LLM“凭感觉” 判断波动和流动性
冲突解释、定向问题生成	LLM Diagnosis/Critic	需要语义理解与跨模态理由整合
Router 第一版	MLP/规则 + 可选 LLM 解释	选择本身要可验证，LLM 解释不能替代数值 Score
Portfolio hard constraints	传统 Optimizer/风控系统	行业、Beta、单票、换手等硬约束不可由 LLM 覆盖

8. 数据、实验与评价体系

8.1 数据与基线

公开研究中的 A 股多智能体数据设置覆盖 SSE50、CSI300、创业板 100 等股票池，包含新闻、财报摘要、价量、基本面及宏观指标；公开资源中也提供了可用于复现实验的 SSE50 示例数据。第一阶段优先在公开 SSE50 数据上建立统一 Benchmark，随后如具备数据权限，再扩展 CSI300/CSI A500 或比赛指定数据。正式实验中的公开基线 MASS 将区分 MASS-Paper（按论文公式与参数实现）与 MASS-Code（按官方开源仓库当前实现运行），以避免论文描述与公开实现口径差异影响公平比较。所有新增数据必须遵守 Point-in-Time 可得性，训练、路由、聚合和回测均不得使用未来信息。

8.2 阶段性验证实验（已完成）

在进入大规模消融实验之前，团队已在公开 SSE50 示例数据上完成系统端到端验证实验。实验设置为：两类投资者类型智能体（num_investor_type=2，每类 1 个 Agent），候选股票池 10 只、每日选择 3 只，时间区间 2023 年 1 月 3 日至 2023 年 1 月 31 日，共 16 个交易日。系统完整执行了从数据读取、智能体初始化、市场状态编码、智能体路由、投资判断、分歧诊断、信号聚合到 IC 评估的全流程，LLM 服务通过环境变量配置并完成 DeepSeek 等 OpenAI 格式接口适配。各预测周期的 IC 评估结果如下：

预测周期	**IC**	**ICIR**	**RankIC**	**RankICIR**
1 日	0.0026	0.0342	0.0247	0.2413
5 日	-0.0762	-0.6935	-0.0916	-0.6742
10 日	-0.0666	-1.9825	-0.0742	-1.4008

从结果看，1 日预测周期的 IC 与 RankIC 在该小样本测试中为正，但样本仅包含 16 个交易日，当前结果不足以支持统计显著的预测能力结论；5 日与 10 日周期结果偏弱，符合系统完成主流程搭建初期的预期——智能体数量、样本长度、聚合参数与提示词鲁棒性尚未充分优化。当前阶段性实验尚未对 Consensus 与不同类型 Disagreement 的独立预测信息进行充分分解，该问题将在 8.3 节 Innovation 2 的正式消融实验中通过 Consensus、Consensus−σ、Diagnosis 及 Diagnosis+Debate+Abstain 的统一对比进行验证。

需要明确的是，本轮实验的主要目的在于验证从数据读取、市场状态编码、Agent 路由、投资判断、分歧处理、信号聚合到评价指标计算的端到端工程闭环能够稳定运行，而非得出最终策略绩效结论；更严格的结论将在第 8.3 节核心实验矩阵的大规模消融、性能–成本前沿与 Regime 解释性实验中得出。

8.3 核心实验矩阵

实验	对比组	主要回答的问题
Innovation 1	公开基线 MASS（MASS-Paper / MASS-Code）/ Router-only / Aggregator-only / Router+Aggregator	事前选择与事后信任是否都有增益
Innovation 2	Consensus / Consensus−σ / Diagnosis / Diagnosis+Debate+Abstain	结构化冲突处理是否优于统一惩罚
Innovation 3	Top-K / Diversity-aware / Diversity+Cost-aware	互补性是否提升有效信息；相同表现下能否减少调用成本
Full System	公开强基线（含 MASS-Paper / MASS-Code）vs AlphaOrchestra	综合收益、风险、换手、成本与解释性是否改善

Stress/OOS	不同 Regime、不同股票池、不同 LLM、不同预算	效果是否依赖单一模型或单一市场环境

8.4 评价指标

维度	指标
预测质量	RankIC、IC、RICIR/ICIR、Hit Rate
组合绩效	Annualized Return、Sharpe、Max Drawdown、Excess Return
交易可行性	Turnover、Transaction Cost、持仓集中度
Agent 效率	Agent Calls、Token/API Cost、Latency、Performance–Cost Frontier
自适应性	Regime 切换恢复时间、不同 Regime 下 Selection 分布
冲突治理	Debate Trigger Rate、Resolution Success、Abstention Rate
可解释性	Selection 理由可追溯率、Evidence Coverage、决策轨迹复现率

8.5 数据泄漏与统计可信度

现有多智能体金融研究已经专门讨论 LLM 历史记忆导致的数据泄漏风险，并通过未见数据进行额外验证。本项目进一步要求所有 Router/Aggregator 学习只使用决策时点以前的市场信息；任何用未来收益计算出的能力分数只能在其真实可获得后进入下一期 Memory。最终报告应同时展示 Walk-forward/OOS、不同 seed，以及在可能条件下的跨股票池验证，避免把单次回测最优当作产品能力。

9. MVP、演示与产品形态



图 2 商业化路径：从可复现实验到 Shadow Mode 再到私有化部署

9.1 MVP 核心演示场景：可观测的多智能体动态决策闭环

MVP 选取具有显著市场状态变化的典型交易日或时间窗口，展示 AlphaOrchestra 从市场状态识别、专家路由、分歧诊断到动态聚合的端到端决策过程。当前已完成的阶段性 Demo 包括 Market State Encoder、基础 Routing、Expert 执行、基础 disagreement severity / exposure control、Signal Aggregation、IC / RankIC 评价与基础调用 Trace。系统首先生成 Market State Card；Routing Agent 根据当前市场状态、专家历史表现与预算，从候选 Expert Type 池中选择一组异构专家，而非固定调用全部 Agent。各专家按照统一结构输出预测方向、置信度、证据、投资期限与推理依据；现阶段已支持基础分歧严重度识别与风险暴露控制，比赛最终 MVP 计划补齐 LLM-based disagreement attribution、Targeted Debate、Agent Similarity Matrix、Dynamic Computation Budget 与更完整 Conflict Console。最终，Aggregation Agent 根据市场状态、历史先验与经冲突处理后的 Type-level 专家意见生成动态信任权重 d_t，形成最终 Alpha 排序与组合决策信号。系统同时记录 Agent 调用数量、Token 消耗、推理时延等运行指标，用于量化比较全量调用与自适应编排机制在投资表现与计算成本之间的效率差异。

9.2 MVP 四个页面

页面	内容	评委看到的价值
Market & Agent Map	Regime、Agent Profile、历史表现、相似度	系统知道 “现在是什么市场” 和 “每个专家擅长什么”
Routing Trace	谁被选/没被选、Selection Score、成本	动态组队，不是固定流水线
Conflict Console	预测、证据、期限、置信度、冲突类型、Debate	分歧被解释和处理，而非统一扣分
Portfolio & Cost	最终 Alpha、权重、收益风险、Token/延迟、基线对比	同时证明效果与工程经济性

注：当前实验链路已支持上述四页中已实现模块的数据产出；完整四页 MVP 将在补齐 Targeted Debate、Agent Similarity Matrix 与 Dynamic Budget 后形成。

9.3 POC 版产品形态

机构 POC 建议采用私有化或 VPC 部署，数据不出域。Agent 编排层以 API 连接客户已有行情、因子库、LLM Gateway、风险模型与回测器；部署前先运行 4–8 周 Shadow Mode，仅输出建议与完整 Trace，不直接影响真实仓位。达到预设稳定性、成本和风险门槛后，再由客户决定是否进入人机协同流程。

10. 目标市场与客户画像

10.1 市场不是“全中国 AUM”，而是可付费的机构投研软件预算

市场测算采用自下而上方法，不把 7 万亿元私募证券基金规模直接当作软件 TAM。初始客户单元是“拥有系统化投研团队、可提供结构化数据、具有 LLM/AI 试点预算、且对私有化和合规有明确要求的机构”。

市场层级	口径（规划假设）	年收入机会测算
Beachhead / SOM	三年内 15 家付费机构，平均年合同 60 万元	约 900 万元/年
初始 SAM	约 300 家量化/系统化程度较高机构 × 50 万元年客单	约 1.5 亿元/年
扩展 SAM	约 800 家私募、券商资管、公募/金融科技机构 × 50 万元	约 4 亿元/年

上述机构数量与客单价均是商业规划假设，用于展示单位经济模型，而不是外部审计的行业市场规模。正式融资或商业化前应通过 20–30 家目标客户访谈校正。

10.2 客户画像与购买触发点

客户	典型触发点	主要采购人	价值证明
百亿/中大型量化私募	Agent 调用成本高、策略拥挤、需要多模态研究	投研负责人/CTO	同表现降成本、Regime 适应、Trace
券商自营/资管	合规与系统治理要求更高	量化负责人/科技/风险	私有化、权限、审计、硬风险约束
公募量化/指数增强	需要稳定性与研究协同	基金经理/量化研究	稳健性、组合风险、研究可复现
金融科技平台	希望增强现有回测/因子平台 Agent 能力	产品/算法负责人	可插拔 Agentic Control Plane

11. 竞争格局与差异化壁垒

11.1 竞争不是“没有竞品”，而是四类替代方案

类别	代表/现状	优势	**AlphaOrchestra** 差异
传统量化平台	Qlib、自研回测/因子平台	可靠、成熟、工具丰富	在其上增加多 Agent 选择、冲突治理和成本编排，不替换底层工具
单/多 Agent 交易框架	TradingAgents、FinCON 等	角色分工、自然语言推理	更聚焦事前动态路由、结构化分歧和成本–多样性目标
多 Agent 组合研究	MASS 等	大规模异构 Agent 与动态权重提供了重要研究参照	AlphaOrchestra 进一步强调事前动态组队、结构化冲突治理与动态计算预算
机构内部人工流程	研究员手工看多个模型/报告	经验强、可灵活判断	把重复的 “找专家—对冲突—做记录” 结构化、自动化和可复现

Qlib 本身覆盖数据处理、模型训练、回测、风险、组合优化和执行等完整量化链路，并已引入 RD-Agent 做自动 R&D。AlphaOrchestra 不应宣称替代 Qlib，而应将其视为可连接的 Quant Tool Layer；真正差异化的是 “跨异构投资 Agent 的动态选择—冲突诊断—成本治理”。

对最重要的公开参照 MASS，竞合边界可以一句话界定：MASS 验证了 “Agent 越多越强” 的规模化方向；AlphaOrchestra 在此基础上解决规模化之后的经济性与治理问题——同等绩效下压缩 Agent/Token 调用、让冲突可审计可干预。MASS 论文与开源代码将作为本项目消融实验的公开基线，核验结果以可复现方式回馈开源社区。

11.2 可形成的五类壁垒

壁垒	形成方式
数据壁垒	客户私有数据上的 Regime—Agent 能力矩阵与冲突历史，不需要外泄原始数据
经验壁垒	Agent Reputation、相似度与 Debate outcome 构成可持续 Memory
系统壁垒	Router、Diagnosis、Aggregator 与量化 Tool API 形成完整可治理控制面
评估壁垒	Performance–Cost Frontier、Regime 恢复、冲突解决等专有评测体系
交付壁垒	金融机构私有化、权限、审计、Fallback 与 Human-in-the-loop 工程经验

12. 商业模式与定价

12.1 商业模式

项目采取 B2B“POC → 私有化订阅/License → 企业级平台/API” 的渐进模式。早期不以公开 SaaS 直接处理客户核心交易数据，而以私有化部署和 Shadow Mode 降低信任门槛。收入由软件许可、部署与适配服务、增值模块和可选推理资源管理组成。

产品层级	建议价格（规划值）	交付内容
研究 POC	8–20 万元 / 4–8 周	1 个股票池、1–2 个 LLM、Router/Diagnosis/Aggregator、对比实验与报告
Research Edition	30–80 万元/年	私有部署、多个策略/股票池、用户权限、Trace、成本看板、年度升级
Enterprise Edition	80–200 万元/年起	高可用、模型网关、风控/回测系统集成、审计、SLA、定制 Agent Registry
API / Academic	按席位或调用量	适合平台方、科研机构或非敏感数据场景

价格为参赛阶段的建议报价区间，尚未经过真实客户成交验证。提交前最好完成至少 5–10 次目标客户访谈，把 “愿意付多少钱” 与 “采购流程多久” 写成访谈证据。

12.2 客户 ROI 的计算方式

不把 ROI 写成 “增加多少收益” 单一维度，而用三条可审计公式：① 推理节省 = 基线 Agent Calls/Token − 实际 Calls/Token；② 研究效率 = 单个可接受策略/信号所需的实验轮次与工程小时；③ 风险收益 = 相同或更低 MDD/Turnover 条件下的 RankIC/Sharpe 变化。对于客户而言，只要系统能在接近投资表现的前提下显著降低大模型调用、研究重复与治理成本，就有独立于 “收益承诺” 的付费理由。

13. 市场进入与机构落地路径

13.1 先从 “研究工具” 切入，而不是直接申请交易权限

第一阶段聚焦投研部门，提供可复现实验、Agent 选择与冲突报告；第二阶段进入 Shadow Mode，与现有策略并行运行；第三阶段才讨论把经过审批的 Alpha Score 送入客户已有 Optimizer。这个顺序既降低金融风险，也让销售更容易从 “科研 POC” 进入 “生产级预算”。

13.2 获客路径

阶段	动作	验证指标
0–3 个月	比赛/论文/开源 Demo，访谈量化私募与券商团队	10–20 个访谈、3 个明确痛点、2 个 POC 意向
3–6 个月	与 1–3 家机构做脱敏或私有数据 POC	完成基线复现、成本节省、OOS 稳定性报告
6–12 个月	推出 Research Edition 与标准 Tool API	首批年费客户、交付周期 <4 周、续费意向
12 个月后	扩展证券/公募/资管与多市场	多模型、多市场、合规审计与渠道合作

13.3 合作生态

平台不必自建所有能力。数据侧可接 Wind/Choice/聚宽/BigQuant/客户自有库；模型侧通过统一 LLM Gateway 适配 Qwen、DeepSeek 及客户自部署模型；量化底座可与 Qlib 或自研 Backtester/Optimizer 协同；部署侧优先支持客户 VPC/本地化。产品竞争力来自 “编排与治理层”，而不是锁死某一家模型或数据供应商。

14. 合规、风险治理与知识产权

14.1 金融风险边界

风险	控制措施
未经验证的策略直接交易	默认 Research/Shadow Mode；Agent 无直接交易权限；最终通过传统 Optimizer 与人工/系统审批
市场 Regime 突变/OOD	检测异常状态，提高预算或进入保守 Fallback；允许 Abstain
交易成本/流动性失真	回测纳入 Turnover、transaction cost、涨跌停与可交易性约束
模型幻觉	统计与风险指标由确定性 Tool 计算；LLM 只能解释和选择动作，不可伪造数值
数据泄漏	PIT 切分、未来收益延迟写回、版本化数据与严格 OOS
大模型供应商不可用	多模型 Gateway、超时/预算 Fallback、关键流程不依赖单一 API

14.2 监管与审计

程序化交易监管强调报告、交易监测、风险防控和信息系统管理，因此产品化时应把 “权限、审计、Fallback、系统稳定性” 作为一等功能，而非 Demo 后补。所有 Agent 输入、模型版本、Selection、Tool 结果、Debate、最终信号和人工审批均应写入不可变更或可追踪日志；风险阈值由机构配置，LLM 不能覆盖硬限制。

14.3 开源与知识产权边界

项目核心架构与新增算法模块由团队自主设计与实现，包括 Router、structured disagreement、conditional debate、cost-aware objective、dynamic budget、Evidence Trace 及相关评测体系。实验过程中使用的公开论文、数据、模型或开源 Benchmark 将按其许可证和学术规范保留引用；第三方公开实现用于对比与结果核验，不作为 AlphaOrchestra 核心产品模块。比赛材料严格区分公开研究结论与团队自有创新、代码和实验结果。

知识产权表达原则 AlphaOrchestra 的核心架构、关键算法模块与产品化控制面由团队自主设计实现；公开论文、数据和 Benchmark 用于相关研究、对照实验与结果核验，并按许可证和学术规范引用。商业化版本以团队自有代码与接口为核心，第三方公开实现不构成核心产品模块。

15. 里程碑与研发路线

阶段	时间	技术交付	商业/比赛交付
M0 Benchmark	第 1–2 周	跑通 SSE50 公开强基线（含 MASS）；固定 seed 与指标	Benchmark 复现报告、Demo 骨架
M1 Routing	第 3–4 周	Market State + Router + Cost Tracker	Innovation 1 消融、调用节省
M2 Diagnosis	第 5–6 周	Structured Output + Diagnosis + Targeted Debate/Abstain	冲突案例、可解释 Trace
M3 Aggregation	第 7–8 周	Adaptive Aggregator + Reputation Memory	三项创新全系统对比
M4 Robustness	第 9–10 周	Regime/OOS/预算/LLM 敏感性测试	Performance–Cost Frontier
M5 Product	第 11–12 周	Dashboard、权限、Shadow Mode 接口	比赛路演、机构 POC 材料
M6 Pilot	3–6 个月	客户私有数据适配、风险/Optimizer 接口	1–3 家 POC、访谈与迭代

15.1 技术升级路线

第一版不建议直接训练复杂 RL Router。先用 MLP/规则把闭环、数据和评测跑通，再利用累计的 “Market State → Selected Agents → Output → Conflict → Action → Portfolio Feedback” 轨迹训练轻量 Router；只有当离线轨迹质量和奖励函数稳定后，再考虑 Contextual Bandit、DPP/Submodular Selection 或 RL orchestration。这样更符合工程节奏，也与当前多 Agent 动态编排研究的经验一致。

15.2 资源需求与资金用途

以下资源需求为完成第 8.3 节实验矩阵与后续产品化验证所需的测算值，不是已发生的支出；金额以人民币万元计。

资源项	主要用途	测算依据	预估投入（万元）
LLM API 与推理费用	运行第 8.3 节核心消融矩阵、Stress/OOS 与多 LLM 敏感性实验	按 MASS 论文公开数据，512-Agent 配置下单日三股票池合计约 4.1 美元；全量单轮（约 250 个交易日）约 0.1 万美元；计入多组消融、缓存与低频更新折扣及调试重复运行	2–5
数据采购	公开 SSE50 示例数据起步；扩展 CSI300/CSI A500 等机构级 Point-in-Time 数据	公开数据免费；机构级数据按行业常见年费区间预留	5–15（视数据权限）
算力与开发环境	回测并发、Router/Aggregator 训练与长周期实验运行	本地开发为主，云端按需弹性扩容	1–3
差旅与机构交流	线下集训、目标机构访谈与 POC 沟通	按国内差旅标准估算	1–2

资金用途分两档：比赛阶段（约 3 个月）优先保障实验矩阵完成与 MVP 演示打磨；若进入孵化阶段，投入重点转向数据权限获取、POC 交付与合规审计能力建设。实际支出将根据数据获取进展与合作情况动态调整。

16. 三年财务情景测算

重要说明下表是商业模式验证用的 Base-case 情景，不是已实现营收，也不是融资承诺。HBS 建议创业计划避免对远期数字制造虚假的精确感；因此这里只用客户数、客单价和团队成本解释 “如果有客户，这门生意是否可能成立”。

项目	第 **1** 年	第 **2** 年	第 **3** 年
付费 POC（个）	4	8	12
年费/企业客户（个）	1	6	15
POC 平均收入（万元）	12	12	12

项目	第 1 年	第 2 年	第 3 年
年费/企业平均合同（万元）	35	45	55
其他实施/增值收入（万元）	0	60	120
预计收入（万元）	83	426	1089
团队与研发成本（万元）	120	220	420
云/LLM/数据与交付成本（万元）	35	80	160
销售管理及其他（万元）	25	70	150
经营结果（万元，粗略）	-97	56	359

盈亏测算的敏感变量不是 “股票收益率”，而是客户转化率、年合同金额、POC 转年费比例和私有化交付成本。若没有机构愿意为节省 Agent 成本、提升可治理性与投研效率付费，则技术再漂亮也不能成立；因此比赛后最重要的商业验证是客户访谈与 POC，而不是继续拉长财务表。

17. 项目价值、愿景与比赛呈现

17.1 研究价值

项目把多智能体金融研究从 “Agent 越多是否越强” 的 Scaling 问题，转向 “在非平稳市场中，如何以有限预算选择最有效的独立信息通道，并把冲突本身转化为可管理的状态”。三项创新分别对应 Selection、Conflict Resolution 和 Computation 三条相互正交、可消融验证的研究问题。

17.2 工程价值

通过兼容 Qlib、机构自研回测器以及公开研究 Benchmark，把量化计算留给确定性工具、把跨模型选择和语义冲突交给 Agent Controller，形成 “模型是工具，Agent 是编排层，风险系统是最终硬边界” 的可落地工程结构。

17.3 商业价值

商业产品不是 “替客户炒股”，而是机构级 AI Quant Orchestration Layer：减少冗余推理、提高研究流程自动化和可解释性，并将复杂多 Agent 系统从实验室 Demo 升级为可以被科技、投研和风险团队共同管理的基础设施。

17.4 比赛路演应重点展示的四幕

幕	现场画面	一句话
1 市场突变	Regime 从正常切到高波/重大事件	系统先判断 “今天不应照常问所有人”
2 动态组队	Router 从大量 Agent 中选择互补子集	先决定问谁，同时显示省下的 Token/时间
3 冲突诊断	Fundamental 与 News/Policy 意见相反	不是简单做平均，而是解释为什么不同意并定向 Debate
4 动态信任与风控	Aggregator 重算、低信心则 Abstain	最终不是 LLM 拍仓位，而是可审计的 Alpha/置信度交给 Optimizer

愿景成为金融机构 “多智能体投研操作系统” 的编排层：让每一次模型调用都有理由、每一次分歧都有解释、每一元推理成本都有边际价值、每一个最终信号都有可追溯证据。

— END —